

FACTORES DETERMINANTES DEL ÉXITO CINEMATOGRAFICO ENTRE LOS AÑOS (2010–2024)

- Programa: DataXperience
- Grupo de Trabajo: Grupo 4
- Integrantes:
 - Catalina Romero
 - Angie Sanabria
 - David Santiago Moreno
 - Juan Diego Niño

Introducción

En los últimos quince años, la industria del cine cambió por completo. la llegada del streaming, la digitalización de la distribución y las nuevas formas de consumo antes y después de la pandemia transformaron la manera en que vemos películas. Hoy en día, definir qué hace que una entrega sea "exitosa" es un reto complejo, lo que ha llevado a productoras, distribuidoras e inversionistas a apoyarse cada vez más en los datos para tomar decisiones estratégicas.

Tradicionalmente, el éxito de una película se ha medido bajo dos categorías: el desempeño comercial (cuánto recauda en taquilla) y la respuesta del público o la crítica (sus puntuaciones). El problema es que estas dos dimensiones no siempre van de la mano. Invertir millones en producción o lograr una gran recaudación no asegura el aplauso de la audiencia, del mismo modo que un presupuesto modesto no impide que una película se convierta en un hito alabado por la crítica. Un claro reflejo de esto es Prince of Persia: The Sands of Time, que pese a su gran presupuesto resultó en un tropiezo comercial y crítico; frente a casos como Insidious, que con un presupuesto mínimo cautivó al público y dio origen a una de las franquicias de terror más rentables.

Con esto en mente, el objetivo de este proyecto es analizar estas dinámicas utilizando el conjunto de datos Movies Box Office Dataset en el periodo comprendido entre 2010 y 2024. Mediante un proceso que abarca desde la limpieza y preparación de los datos hasta el análisis exploratorio (EDA) y la aplicación de modelos estadísticos, evaluamos cómo interactúan tres factores clave como el género cinematográfico, los ingresos globales y el volumen de votos, esto con el fin de determinar qué hace que una película alcance una calificación superior a 7.5/10.

Planteamiento del problema

En el mercado cinematográfico actual (2010–2024), la inversión financiera en la producción de películas involucra un alto nivel de riesgo. Existe una clara desconexión entre el éxito comercial en taquilla y la percepción de calidad del público o la crítica. Como se evidencia en la industria, presupuestos elevados no garantizan una valoración positiva, mientras que producciones de menor presupuesto pueden alcanzar un reconocimiento crítico sobresaliente.

El problema analítico radica en identificar qué combinación de atributos comerciales y cinematográficos —específicamente el género, los ingresos globales recaudados (\$Worldwide_gross) y el nivel de participación e interés del público reflejado en el número de votos (Vote_Count)— influyen de manera directa y determinante en que un largometraje alcance una valoración alta (definida como una calificación mayor a 7.5/10). Comprender estas relaciones permite a estudios y distribuidores optimizar la asignación de recursos y tomar decisiones mejor fundamentadas.

Pregunta Principal de Investigación

¿Qué factores cinematográficos y comerciales (género, ingresos globales y volumen de votos) se asocian de manera más determinante con que una película alcance una calificación superior a 7.5 entre 2010 y 2024?

Preguntas de Apoyo

- ¿Cuáles son los géneros cinematográficos que concentran el mayor porcentaje de películas con calificación superior a 7.5 entre 2010 y 2024?
- ¿Existe una relación lineal o una correlación significativa entre los ingresos globales en taquilla (\$Worldwide_gross) y la calificación obtenida por la película?
- ¿El volumen de votos registrados (Vote_Count) se relaciona positivamente con calificaciones superiores a 7.5?

- ¿Qué combinación específica de género y rango de ingresos comerciales representa la mayor probabilidad de éxito en calificación (> 7.5)?

Objetivos del Proyecto

Objetivo General

Determinar e interpretar los patrones y factores clave (género, recaudación mundial y volumen de votos) que inciden en que un largometraje alcance el éxito crítico y de audiencia (Rating > 7.5) en el periodo 2010–2024, mediante el procesamiento, análisis exploratorio de datos (EDA) y la aplicación de modelos estadísticos y predictivos.

Objetivos Específicos

1. Limpieza y estructuración de datos: Consolidar una base de datos limpia de 2,864 películas mediante la depuración de duplicados, la corrección de formatos de texto en las variables de calificación y género, y la eliminación de registros con datos faltantes en variables críticas como \$Worldwide, Vote_Count, Rating y Genres, asegurando la calidad del insumo para el análisis estadístico y predictivo.
2. Definir y derivar las variables clave para el análisis de negocio, creando la variable binaria objetivo Exito_Rating (1 para calificaciones mayores a 7.5 y 0 para las demás), aislando el género cinematográfico principal y categorizando los ingresos globales en rangos por percentiles (Bajo, Medio y Alto) para facilitar la identificación de patrones en el análisis exploratorio.
3. Examinar la distribución de las variables comerciales y cinematográficas mediante herramientas de visualización de datos, evaluando el impacto del volumen de votos, el comportamiento de los diferentes géneros y las combinaciones de nivel de ingresos, a fin de identificar correlaciones clave y diferencias de distribución entre las películas exitosas y las convencionales.
4. Entrenar, validar y comparar algoritmos de aprendizaje automático (incluyendo Regresión Logística y Random Forest) sobre la variable binaria Exito_Rating, utilizando métricas de desempeño como Accuracy, ROC-AUC y matrices de confusión, con el propósito de determinar qué factores ofrecen el mayor valor explicativo y predictivo respecto al éxito de una producción cinematográfica.

Comprensión del conjunto de Datos

Para este proyecto, los datos se obtuvieron del repositorio público Kaggle, a partir del conjunto Movies Box Office Dataset (2000–2024) publicado por Aditya Jilla (Jilla, 2024). Se eligió esta fuente por ser la opción más completa y confiable de acceso libre, al reunir de forma centralizada tanto el desempeño comercial como la recepción de la audiencia a nivel global (Jilla, 2024).

De la base original se seleccionó una muestra reducida de 2,864 películas lanzadas entre 2010 y 2024. Tras realizar procesos de depuración, eliminación de nulos y estandarización de formatos, se consolidó el conjunto final sobre el cual se construyeron los análisis exploratorios y modelos predictivos.

La importancia de este conjunto de datos y una de las razones por la que lo elegimos fue por la combinación de variables comerciales y cualitativas que permiten evaluar el éxito cinematográfico, como lo son:

- \$Worldwide: Variable numérica que indica los ingresos totales recopilados en la taquilla mundial. Es la métrica principal para medir el éxito económico.
- Rating: Puntuación promedio otorgada por la audiencia (escala de 1 a 10). Representa la aceptación crítica del público.
- Vote_Count: Cantidad total de votos recibidos por la película. Refleja la popularidad y el volumen de alcance de la producción.
- Genres: Géneros cinematográficos asignados a la película. Permite categorizar el tipo de contenido y analizar preferencias de audiencia por género principal.
- Exito_Rating (Variable transformada): Variable binaria derivada (1 o 0) que define si la película fue un éxito crítico (calificación > 7.5) o no.
- Nivel_Ingresos (Variable transformada): Categorización del ingreso global en rangos (Bajo, Medio, Alto) para facilitar la segmentación en el análisis exploratorio.

✓ Limpieza y preparación de los datos

Antes de proceder con la depuración y transformación del conjunto de datos, se debe alistar primero el entorno de trabajo en Python. Para ello, se importaron las librerías fundamentales que facilitan la manipulación estructurada de información (pandas y numpy), la visualización gráfica de patrones estadísticos (matplotlib y seaborn), así como los módulos especializados de scikit-learn para el

procesamiento de variables, la división del dataset y el entrenamiento y evaluación de modelos de Machine Learning (Regresión Logística y Random Forest).

Asimismo, se definió una configuración visual estándar para los gráficos, asegurando consistencia estética, visibilidad y un formato adecuado en los análisis exploratorios que se derivan de la base de datos limpia.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# Modelos y métricas de Machine Learning
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score, roc_auc_score, ConfusionMatrixDisplay

# Configuración visual para nuestras gráficas
sns.set_style('whitegrid')
plt.rcParams['figure.figsize'] = (9, 5)
plt.rcParams['axes.spines.top'] = False
plt.rcParams['axes.spines.right'] = False
```

1. Carga, Filtrado y Limpieza de Datos

En esta primera etapa se procedió con la lectura del conjunto de datos crudo original. Con el objetivo de delimitar un horizonte temporal relevante, actualizado y homogéneo para la industria cinematográfica moderna, se filtró la información para analizar exclusivamente las películas producidas entre el periodo 2010 y 2024.

Posteriormente, se ejecutó una rutina rigurosa de depuración para garantizar la integridad y calidad analítica de los datos:

- Se identificaron y eliminaron los registros idénticos repetidos en la fuente cruda.
- Corrección de formatos y estandarización de tipos: Se eliminaron de Rating sufijos de formato (como '/10') y espacios para convertirla a un valor numérico, se hizo conversión a tipo numérico en las variables de volumen de votos e ingresos y además se estandarizaron las cadenas de texto en los géneros cinematográficos a formato título para evitar categorías redundantes por discrepancias de escritura.
- Se descartaron los datos nulos o vacíos en las columnas críticas para prevenir sesgos en el análisis exploratorio y evitar distorsiones en el posterior entrenamiento de los modelos predictivos.

Como resultado de este proceso, la base de datos se redujo a una muestra limpia y estructurada de 2,864 producciones cinematográficas analizables.

```
# Cargamos la base de datos cruda original
try:
    df = pd.read_csv('enhanced_box_office_data(2000-2024)u.csv')
except FileNotFoundError:
    print("Por favor, asegúrate de subir el archivo 'enhanced_box_office_data(2000-2024)u.csv'")
    df = pd.DataFrame()

if not df.empty:
    # 1. Filtramos el periodo 2010 - 2024
    df = df[(df['Year'] >= 2010) & (df['Year'] <= 2024)].copy()

    # 2. Eliminamos los duplicados exactos que encontramos en la base cruda
    df = df.drop_duplicates().reset_index(drop=True)

    # 3. Corregimos los formatos
    # Limpiamos 'Rating' quitando el '/10' y los espacios, convirtiéndolo a número
    df['Rating'] = df['Rating'].astype(str).str.replace('/10', '', regex=False).str.strip()
    df['Rating'] = pd.to_numeric(df['Rating'], errors='coerce')

    # Aseguramos que los ingresos y los votos sean numéricos
    df['$Worldwide'] = pd.to_numeric(df['$Worldwide'], errors='coerce')
    df['Vote_Count'] = pd.to_numeric(df['Vote_Count'], errors='coerce')

    # Limpiamos los géneros unificando mayúsculas y minúsculas (Title Case)
    df['Genres'] = df['Genres'].astype(str).str.strip().str.title()
    df['Genres'] = df['Genres'].replace(['Nan', 'None', ''], np.nan)

    # 4. Manejamos los valores nulos (borramos las filas incompletas en variables críticas)
```

```

columnas_clave = ['Rating', '$Worldwide', 'Vote_Count', 'Genres']
df = df.dropna(subset=columnas_clave).copy()

print(f"Base limpia lista. Total de películas que analizaremos: {len(df)}")
display(df.head(3))

```

Base limpia lista. Total de películas que analizaremos: 2864

	Rank	Release Group	\$Worldwide	\$Domestic	Domestic %	\$Foreign	Foreign %	Year	Genres	Rating	Vote_Count	Original_Language
0	1	Toy Story 3	1.066970e+09	415004880.0	38.9	651964823.0	61.1	2010	Animation, Family, Comedy	7.800	147110.0	English
1	2	Alice in Wonderland	1.025467e+09	334191110.0	32.6	691276000.0	67.4	2010	Family, Fantasy, Adventure	6.640	13979.0	English
2	3	Harry Potter and the Deathly Hallows - Part 2	9.602833e+08	295983305.0	30.8	664300000.0	69.2	2010	Adventure, Fantasy	7.746	19120.0	English

2. Creación de Variables Objetivo y Categorías

Una vez limpia la base de datos, avanzamos con la ingeniería variables para transformar las columnas originales en variables estructuradas que respondan directamente a la pregunta central del proyecto: *¿qué define el éxito de una película y cómo se relacionan sus características principales?*

Para esto, creamos tres variables clave que nos facilitan el análisis:

- Variable objetivo (Exitó_Rating): Definimos una métrica de éxito donde asignamos un valor de 1 a las películas que alcanzaron una calificación superior a 7.5 y 0 a las que no. Esto nos permite convertir la puntuación en un problema claro de clasificación.
- Simplificación del género (Genero_Principal): Como una película puede tener varios géneros asignados, extrajimos únicamente la primera categoría listada para simplificar la comparación. Además, agrupamos aquellos géneros con muy pocas películas en la categoría "Otros", evitando ruido en los datos.
- Segmentación comercial (Rango_Ingresos): Para analizar cómo influye la recaudación sin depender únicamente de cifras absolutas, dividimos las ganancias globales en tres niveles iguales (Bajo, Medio y Alto) utilizando percentiles (33% y 66%). Esta categorización resulta especialmente útil para cruzarlas en visualizaciones y mapas de calor.

```

if not df.empty:
    # Definimos nuestra métrica de éxito
    df['Exitó_Rating'] = (df['Rating'] > 7.5).astype(int)

    # Extraemos el género principal (la primera palabra antes de la coma)
    df['Genero_Principal'] = df['Genres'].apply(lambda x: str(x).split(',')[0].strip())

    # Agrupamos géneros muy pequeños en 'Otros'
    conteo_generos = df['Genero_Principal'].value_counts()
    generos_validos = conteo_generos[conteo_generos >= 20].index
    df['Genero_Principal'] = df['Genero_Principal'].apply(lambda x: x if x in generos_validos else 'Otros')

    # Creamos la categoría de Rango_Ingresos basándonos en los percentiles 33% y 66%
    q_ingresos = df['$Worldwide'].quantile([0.33, 0.66])
    df['Rango_Ingresos'] = pd.cut(
        df['$Worldwide'],
        bins=[-1, q_ingresos[0.33], q_ingresos[0.66], np.inf],
        labels=['Bajo', 'Medio', 'Alto']
    )

    print("Distribución de nuestra variable objetivo (Exitó_Rating):")
    print(df['Exitó_Rating'].value_counts(normalize=True).round(3))

```

```

Distribución de nuestra variable objetivo (Exitó_Rating):
Exitó_Rating
0      0.872
1      0.128
Name: proportion, dtype: float64


```

3. Análisis Exploratorio de Datos (EDA)

Para esta fase se desarrollaron las visualizaciones analíticas fundamentales presentadas durante la sustentación del proyecto, con el propósito de identificar patrones de comportamiento, distribuciones y relaciones entre las variables clave.

En primer lugar, se evaluó la tasa de éxito (porcentaje de películas con calificación superior a 7.5) según el género cinematográfico principal; en segundo lugar, se analizó la distribución del volumen de votos (Vote_Count) mediante diagramas de caja en escala logarítmica para comparar el nivel de popularidad entre películas exitosas y no exitosas; y finalmente, se construyó un mapa de calor para examinar la interacción conjunta entre los géneros cinematográficos y los rangos de ingresos (Bajo, Medio y Alto), permitiendo descubrir combinaciones comerciales y creativas asociadas a un mayor desempeño crítico.

```
if not df.empty:
    # --- Gráfica 1: Tasa de éxito por género ---
    tasa_exito_genero = df.groupby('Genero_Principal')['Exito_Rating'].mean().sort_values(ascending=False).reset_index()
    fig, ax = plt.subplots(figsize=(7, 5))
    sns.barplot(data=tasa_exito_genero, x='Exito_Rating', y='Genero_Principal', color='#343a40', ax=ax)
    ax.set_title('Porcentaje de películas exitosas (Rating > 7.5) por género principal', fontsize=14)
    ax.set_xlabel('% de éxito')
    ax.set_ylabel('')
    plt.tight_layout()
    plt.show()
```




```
if not df.empty:
    # --- Gráfica 2: Boxplot de Volumen de Votos según Éxito (Escala Logarítmica) ---
    fig, ax = plt.subplots(figsize=(6, 4))
    sns.boxplot(data=df, x='Exito_Rating', y='Vote_Count', palette=['#cce3de', '#a4c3b2'], ax=ax)
    ax.set_yscale('log')
    ax.set_title('Volumen de votos según Exito_Rating', fontsize=14)
    ax.set_xlabel('¿Exito_Rating (Rating > 7.5)?')
    ax.set_ylabel('Vote_Count (escala log)')
    ax.set_xticklabels(['False', 'True'])
    plt.tight_layout()
    plt.show()

    # --- Gráfica 3: Heatmap de % de éxito por género y rango de ingresos ---
    heatmap_data = df.groupby(['Genero_Principal', 'Rango_Ingresos'], observed=False)['Exito_Rating'].mean().unstack() * 100
    fig, ax = plt.subplots(figsize=(6, 5))
    sns.heatmap(heatmap_data, annot=True, fmt=".0f", cmap="Blues", cbar_kws={'label': '% de éxito'}, ax=ax)
    ax.set_title('% de éxito por género y rango de ingresos', fontsize=14)
    ax.set_xlabel('Rango Ingresos')
    ax.set_ylabel('Genero_Principal')
    plt.tight_layout()
    plt.show()
```

```
/tmp/ipykernel_3202/3606787885.py:4: FutureWarning:
```

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set

```
sns.boxplot(data=df, x='Exito_Rating', y='Vote_Count', palette=['#c3e3de', '#a4c3b2'], ax=ax)
/tmp/ipykernel_3202/3606787885.py:9: UserWarning: set_ticklabels() should only be used with a fixed number of ticks, i.e. after
ax.set_xticklabels(['False', 'True'])
```




Matriz de Correlación de Variables Numéricas

Esta primera visualización corresponde a un mapa de calor (heatmap), una herramienta fundamental en el análisis exploratorio de datos que permite evaluar la fuerza y dirección de las relaciones lineales entre las distintas variables cuantitativas del dataset. Cada celda de la matriz representa el coeficiente de correlación de Pearson, desplegado en una escala de colores donde los tonos rojos denotan una correlación positiva fuerte y los tonos azules una correlación negativa. Destaca de manera clara la altísima asociación directa entre las variables financieras como Worldwide, Domestic, Foreign e Ingresos_Millones (con valores cercanos o iguales a 1.00), así como una relación positiva relevante entre la cantidad de votos y la recaudación general. Por otro lado, variables como Rating y Exito_Rating presentan una correlación modesta con respecto a los ingresos comerciales, sugiriendo que la recepción crítica y el éxito financiero responden a factores parcialmente independientes.

```
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# Matriz de Correlación
plt.figure(figsize=(8, 5))
numeric_cols = df.select_dtypes(include=[np.number]).columns
correlation_matrix = df[numeric_cols].corr()
```

```
sns.heatmap(correlation_matrix, annot=True, cmap="coolwarm", fmt=".2f", linewidths=0.5)
plt.title("Matriz de Correlación de Variables Numéricas")
plt.show()
```



Distribución de Ingresos según Éxito por Rating

La segunda gráfica consiste en un diagrama de caja y bigotes (boxplot), utilizado para comparar la distribución de una variable continua (Ingresos_Millones) a través de las categorías de una variable dicotómica (Exito_Rating, donde 0 representa películas que no alcanzaron el umbral de éxito por crítica y 1 las que si lo superaron). Este gráfico permite identificar de forma intuitiva la mediana, los cuartiles (Q1 y Q3) y la dispersión general del recaudo en ambos grupos, resaltando además la presencia de valores atípicos (outliers) en las producciones con ingresos extraordinarios. A través de este análisis visual, es posible contrastar si las películas aclamadas por la audiencia y la crítica tienden a generar mayores ingresos en taquilla o si, por el contrario, la variabilidad financiera se mantiene uniforme independientemente del nivel de calificación obtenido.


```
# Boxplots de Ingresos según el Éxito por Rating
plt.figure(figsize=(6, 4))

df['Ingresos_Millones'] = df['$Worldwide'] / 1_000_000
sns.boxplot(x="Exito_Rating", y="Ingresos_Millones", data=df, palette="Set2")
plt.title("Distribución de Ingresos según Éxito por Rating")
plt.xlabel("Éxito por Rating (0: No, 1: Si)")
plt.ylabel("Ingresos (en Millones)")
plt.show()
```

```
/tmp/ipykernel_3202/1496003527.py:5: FutureWarning:
```

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set

```
sns.boxplot(x="Exito_Rating", y="Ingresos_Millones", data=df, palette="Set2")
```



4. Modelado Estadístico y de Machine Learning

En esta etapa se transformo la información procesada en un formato apto para los algoritmos de clasificación de Machine Learning. Para lograrlo, las variables categóricas de texto (como el género principal) se convirtieron en columnas numéricas mediante la técnica de variables dummy (One-Hot Encoding), mientras que los valores numéricos continuos de ingresos y votos se estandarizaron con un escalador (StandardScaler). Este último paso ajusta las escalas de cada columna para evitar que las variables con números más grandes ejerzan un peso desproporcionado sobre la Regresión Logística y distorsionen las predicciones del modelo.

```
if not df.empty:
    # 1. Convertimos nuestra variable categórica de género en múltiples columnas de 1s y 0s
    df_ml = pd.get_dummies(df[['Vote_Count', '$Worldwide', 'Genero_Principal', 'Exito_Rating']], columns=['Genero_Principal'],

    X = df_ml.drop(columns=['Exito_Rating'])
    y = df_ml['Exito_Rating']
    FEATURE_NAMES = X.columns.tolist()

    # 2. Partición Estratificada: Separamos un 20% de los datos para prueba, manteniendo la proporción original de películas ex
    X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42, stratify=y)

    # 3. Estandarización: Ajustamos la escala basándonos SOLO en el conjunto de entrenamiento.
    scaler = StandardScaler()
    X_train_sc = scaler.fit_transform(X_train)
    X_test_sc = scaler.transform(X_test)

    print("Dimensiones de nuestros datos de entrenamiento:", X_train_sc.shape)
    print("Dimensiones de nuestros datos de prueba:", X_test_sc.shape)
```

```
Dimensiones de nuestros datos de entrenamiento: (2291, 19)
Dimensiones de nuestros datos de prueba: (573, 19)
```

Modelo 1: Regresión Logística

Como primer enfoque predictivo, se entreno un algoritmo de Regresión Logística para clasificar si una película alcanza el éxito crítico o no. Se eligió este modelo debido a su alta interpretabilidad matemática, ya que permite analizar los coeficientes asignados a cada variable e identificar de forma clara cómo el volumen de votos, los ingresos globales o un género específico aumentan o reducen la probabilidad de que una producción obtenga una calificación superior a 7.5.

```
if not df.empty:
    log_reg = LogisticRegression(random_state=42)
    log_reg.fit(X_train_sc, y_train)

    y_pred_log = log_reg.predict(X_test_sc)
    y_proba_log = log_reg.predict_proba(X_test_sc)[:, 1]

    print("--- Resultados de nuestra Regresión Logística ---")
```



```

print(f"Accuracy: {accuracy_score(y_test, y_pred_log):.3f}")
print(f"ROC-AUC: {roc_auc_score(y_test, y_proba_log):.3f}")


fig, ax = plt.subplots(figsize=(5, 4))
ConfusionMatrixDisplay.from_predictions(y_test, y_pred_log, cmap="Blues", ax=ax, colorbar=False)
ax.set_title("Matriz de Confusión - Logística")
plt.show()

```

```

--- Resultados de nuestra Regresión Logística ---
Accuracy: 0.885
ROC-AUC: 0.725

```



Como podemos ver en los resultados del Modelo 1 (Regresión Logística), el algoritmo alcanza una precisión general (Accuracy) del 88.5% y un nivel de separación de 0.725. Sin embargo, al observar la matriz de confusión se evidencia un sesgo importante hacia la clase negativa: el modelo es muy bueno identificando películas no exitosas (clasifico correctamente 496 de 499), pero le cuesta predecir los éxitos reales, acertando solo 11 de los 74 casos positivos y dejando pasar 63 como falsos negativos. Esto ocurre principalmente por el desbalance natural de la base de datos, donde la gran mayoría de las películas no superan el umbral de 7.5 de calificación.

Modelo 2: Random Forest

Como segundo enfoque, se implemento un modelo de ensamble mediante Random Forest. Se selecciono este algoritmo para capturar interacciones no lineales y relaciones complejas entre los ingresos, el genero y la participación de los espectadores que una regresión logística no logra detectar; además, al combinar múltiples árboles de decisión, reduce el riesgo de sobreajuste (overfitting) y proporciona una medición mas precisa sobre la importancia relativa de cada variable en la predicción del éxito.

```

if not df.empty:
    # Random Forest no necesita que escalemos los datos, así que usamos X_train y X_test originales
    rf = RandomForestClassifier(n_estimators=200, max_depth=6, random_state=42, oob_score=True)
    rf.fit(X_train, y_train)

    y_pred_rf = rf.predict(X_test)
    y_proba_rf = rf.predict_proba(X_test)[: , 1]


    print("--- Resultados de nuestro Random Forest ---")
    print(f"Accuracy en test: {accuracy_score(y_test, y_pred_rf):.3f}")
    print(f"ROC-AUC: {roc_auc_score(y_test, y_proba_rf):.3f}\n")

    # Extraemos la importancia de las variables según el modelo
    importancia_rf = pd.Series(rf.feature_importances_, index=FEATURE_NAMES).sort_values(ascending=True).tail(10)

    fig, ax = plt.subplots(figsize=(8, 5))
    importancia_rf.plot(kind="barh", color="#E9A23B", ax=ax)
    ax.set_title("Top 10 - Importancia de Variables (Random Forest)", fontweight='bold')
    ax.set_xlabel("Reducción de impureza promedio")
    plt.show()

```

--- Resultados de nuestro Random Forest ---
Accuracy en test: 0.881
ROC-AUC: 0.699



En el Modelo 2 (Random Forest) obtenemos una precisión general (Accuracy) del 88.1% y un nivel de separación de 0.699, valores muy similares a la Regresión Logística. Lo verdaderamente esencial de este modelo es el gráfico de importancia de variables, el cual demuestra de forma clara que el volumen de votos y los ingresos globales son los factores decisivos que determinan si una película es exitosa. Los géneros individuales (como Animación o Drama) también aportan al modelo, pero su peso es considerablemente menor en comparación con el impacto combinado del interés del público y la recaudación en taquilla.

Conclusiones y Aprendizajes

A partir del desarrollo del proyecto, el análisis exploratorio y los resultados de los modelos predictivos, se obtuvieron las siguientes conclusiones clave sobre los factores que determinan el éxito cinematográfico:

1. La limpieza de datos fue fundamental ya que la comparación entre el conjunto de datos original y el procesado demostró que no era viable confiar en métricas con registros nulos o formatos inconsistentes, es importante garantizar la integridad y estandarización de los datos fue el paso indispensable para asegurar la confiabilidad del modelado predictivo.
2. Tanto la exploración inicial como la métrica de importancia de variables del algoritmo Random Forest confirmaron de forma muy contundente que el volumen de interacción del público es la variable de mayor peso para determinar si una cinta logra una calificación superior a 7.5.
3. El mapa de calor reveló que un mayor nivel de ingresos no garantiza por sí solo el éxito crítico. Géneros como Documental y Música alcanzan altas tasas de aprobación sin requerir grandes recaudaciones en taquilla, mientras que otros como Misterio dependen en mayor medida de estar en el rango de ingresos "Alto" para consolidarse como producciones exitosas.

Referencias

- Jilla, A. (2024). Movies Box Office Dataset (2000–2024) [Conjunto de datos]. Kaggle. <https://www.kaggle.com/datasets/adityajilla/movies-box-office-dataset-2000-2024>
- Silva Gómez, C. (2024). Caja de Herramientas: Cargue, Limpieza y Análisis Exploratorio de Datos (EDA) [Cuaderno de Jupyter/Google Colab]. Material docente de clase, módulo DataXperience.
- Silva Gómez, C. (2024). Modelamiento Estadístico y Machine Learning Aplicado [Presentaciones y material de apoyo de clase]. Módulo DataXperience.
- Google. (2026). Google Colab y Gemini en Colab [Entorno de desarrollo integrado y asistente de IA para optimización de código en Python]. Google Inc.

