

DATA EXPERIENCE ·

GRUPO 4

Factores Determinantes del Éxito Cinematográfico (2010–2024)

Catalina Romero · Angie Sanabria · David Santiago Moreno · Juan Diego Niño



Planteamiento del Problema



¿Qué factores cinematográficos y comerciales determinan el éxito crítico?

- Desconexión entre éxito comercial y crítico
- Alto riesgo en la inversión cinematográfica
- Necesidad de decisiones basadas en datos

Fracaso Prince of Persia

Gran presupuesto de producción y marketing, resultado comercial y crítico decepcionante.

Éxito Insidious

Presupuesto bajo, retorno y recepción crítica muy por encima de lo esperado.



Objetivos del Proyecto



Objetivo general: identificar y modelar los factores que determinan el éxito crítico de una película a partir de sus atributos cinematográficos y comerciales.



Limpieza y estructuración de datos



Derivación de variables clave



Análisis exploratorio (EDA)



Modelado predictivo (Regresión Logística y Random Forest)



Dataset: Comprensión de Datos



Kaggle

Movies Box Office Dataset — Aditya Jilla, 2024

2,864

películas (2010–2024)

5 variables clave

\$Worldwide	Ingresos globales
Rating	Calificación (1–10)
Vote_Count	Participación del público
Genres	Categoría cinematográfica
Exito_Rating	Binaria: >7.5 = éxito

```
if not df.empty:
    # 1. Filtramos el periodo 2010 - 2024
    df = df[(df['Year'] >= 2010) & (df['Year'] <= 2024)].copy()
```

```
# 4. Manejamos los valores nulos (borramos las filas incompletas en variables críticas)
columnas_clave = ['Rating', '$Worldwide', 'Vote_Count', 'Genres']
df = df.dropna(subset=columnas_clave).copy()

print(f"Base limpia lista. Total de películas que analizaremos: {len(df)}")
display(df.head(3))
```



Calidad de Datos: Fundamento del Análisis



- Filtrado temporal (2010–2024)
- Eliminación de duplicados
- Corrección de formatos
- Manejo de valores nulos

2,864

películas válidas en la base limpia

```
# 2. Eliminamos los duplicados exactos que encontramos en la base cruda
df = df.drop_duplicates().reset_index(drop=True)

# 3. Corregimos los formatos
# Limpiamos 'Rating' quitando el '/10' y los espacios, convirtiéndolo a número
df['Rating'] = df['Rating'].astype(str).str.replace('/10', '', regex=False).str.strip()
df['Rating'] = pd.to_numeric(df['Rating'], errors='coerce')

# Aseguramos que los ingresos y los votos sean numéricos
df['$Worldwide'] = pd.to_numeric(df['$Worldwide'], errors='coerce')
df['Vote_Count'] = pd.to_numeric(df['Vote_Count'], errors='coerce')

# Limpiamos los géneros unificando mayúsculas y minúsculas (Title Case)
df['Genres'] = df['Genres'].astype(str).str.strip().str.title()
df['Genres'] = df['Genres'].replace(['Nan', 'None', ''], np.nan)
```



Transformación de Datos para el Análisis



Exito_Rating

Binaria: 1 si Rating > 7.5, 0 si no

Genero_Principal

Primer género de la película

Rango_Ingresos

Bajo, Medio, Alto (por percentiles)

25.8%

Películas exitosas

74.2%

Películas no exitosas

```
if not df.empty:
    # Definimos nuestra métrica de éxito
    df['Exito_Rating'] = (df['Rating'] > 7.5).astype(int)

    # Extraemos el género principal (la primera palabra antes de la coma)
    df['Genero_Principal'] = df['Genres'].apply(lambda x: str(x).split(',')[0].strip())

    # Agrupamos géneros muy pequeños en 'Otros'
    conteo_generos = df['Genero_Principal'].value_counts()
    generos_validos = conteo_generos[conteo_generos >= 20].index
    df['Genero_Principal'] = df['Genero_Principal'].apply(lambda x: x if x in generos_validos else 'Otros')

    # Creamos la categoría de Rango_Ingresos basándonos en los percentiles 33% y 66%
    q_ingresos = df['$Worldwide'].quantile([0.33, 0.66])
    df['Rango_Ingresos'] = pd.cut(
        df['$Worldwide'],
        bins=[-1, q_ingresos[0.33], q_ingresos[0.66], np.inf],
        labels=['Bajo', 'Medio', 'Alto']
    )


    print("Distribución de nuestra variable objetivo (Exito_Rating):")
    print(df['Exito_Rating'].value_counts(normalize=True).round(3))
```



Visualización 1: Tasa de Éxito por Género



Ciertos géneros tienen probabilidades inherentes diferentes de alcanzar altas calificaciones.





Visualización 2: Volumen de Votos vs Éxito




```
# --- Gráfica 2: Boxplot de Volumen de Votos según Éxito (Escala Logarítmica) ---  
fig, ax = plt.subplots(figsize=(8, 5))  
sns.boxplot(data=df, x='Exito_Rating', y='Vote_Count', palette=['#cce3de', '#a4c3b2'], ax=ax)  
ax.set_yscale('log')  
ax.set_title('Volumen de votos según Exito_Rating', fontsize=14)  
ax.set_xlabel('¿Exito_Rating (Rating > 7.5)?')  
ax.set_ylabel('Vote_Count (escala log)')  
ax.set_xticklabels(['False', 'True'])  
plt.show()
```

El volumen de interacción del público es fuertemente indicativo de calidad percibida.



Visualización 3: Matriz de Interacción



PYTHON (FRAGMENTO)

Documentales: altas tasas de éxito incluso con ingresos bajos. Misterio/Thriller requiere ingresos altos. Drama/Comedia: éxito independiente del presupuesto.

```
# --- Gráfica 3: Heatmap de % de éxito por género y rango de ingresos ---
heatmap_data = df.groupby(['Genero_Principal', 'Rango_Ingresos'], observed=False)['Exito_Rating'].mean().unstack() * 100
fig, ax = plt.subplots(figsize=(8, 8))
sns.heatmap(heatmap_data, annot=True, fmt=".0f", cmap="Blues", cbar_kws={'label': '% de éxito'}, ax=ax)
ax.set_title('% de éxito por género y rango de ingresos', fontsize=14)
ax.set_xlabel('Rango Ingresos')
ax.set_ylabel('Genero_Principal')
plt.show()
```



Modelo 1: Regresión Logística



Alta interpretabilidad para entender qué factores influyen.

- StandardScaler para normalización

88.5%

Accuracy

0.725

ROC-AUC

```
# 3. Estandarización: Ajustamos la escala basándonos SOLO en el conjunto de entrenamiento.
scaler = StandardScaler()
X_train_sc = scaler.fit_transform(X_train)
X_test_sc = scaler.transform(X_test)

print("Dimensiones de nuestros datos de entrenamiento:", X_train_sc.shape)
print("Dimensiones de nuestros datos de prueba:", X_test_sc.shape)
```

⚠ Limitación: sesgo hacia la clase mayoritaria (falta detectar películas exitosas)



Modelo 2: Random Forest



Captura interacciones no lineales y proporciona importancia de variables.

Configuración: 200 árboles, profundidad máxima 6


```
if not df.empty:
    # Random Forest no necesita que escalemos los datos, así que usamos X_train y X_test originales
    rf = RandomForestClassifier(n_estimators=200, max_depth=6, random_state=42, oob_score=True)
    rf.fit(X_train, y_train)

    y_pred_rf = rf.predict(X_test)
    y_proba_rf = rf.predict_proba(X_test)[:, 1]

    print("--- Resultados de nuestro Random Forest ---")
    print(f"Accuracy en test: {accuracy_score(y_test, y_pred_rf):.3f}")
    print(f"ROC-AUC: {roc_auc_score(y_test, y_proba_rf):.3f}\n")


    # Extraemos la importancia de las variables según el modelo
    importancia_rf = pd.Series(rf.feature_importances_, index=FEATURE_NAMES).sort_values(ascending=True).tail(10)

    fig, ax = plt.subplots(figsize=(8, 5))
    importancia_rf.plot(kind="barh", color="#E9A23B", ax=ax)
    ax.set_title("Top 10 - Importancia de Variables (Random Forest)", fontweight='bold')
    ax.set_xlabel("Reducción de impureza promedio")
    plt.show()
```






3 Descubrimientos Principales



- 1 El género es un diferenciador significativo: documentales y música tienen tasas de éxito 2x mayores.
- 2 Vote_Count es el predictor más fuerte: las películas exitosas generan 4x más participación.
- 3 Presupuesto ≠ calidad: correlación débil ($r=0.18$) entre ingresos y Rating.





Implicaciones Estratégicas para la Industria



- La limpieza de datos es fundamental: base de todo análisis confiable
- Vote_Count es el factor más determinante de éxito crítico
- Los géneros tienen dinámicas diferentes: no existe una fórmula universal
- Los datos son una herramienta esencial para optimizar decisiones de inversión

Recomendación: segmentación estratégica por género + enfoque en generación de engagement

▢ Referencias y Fuentes

1. Jilla, A. (2024). Movies Box Office Dataset [Kaggle]
2. Silva Gómez, C. (2024). Materiales de clase — DataXperience
3. Google Colab (entorno de desarrollo)

**El éxito cinematográfico es multidimensional:
datos + análisis = decisiones mejores.**